Univerzitet u Beogradu
Matematički fakultet

Predmet: *Istraživanje podataka 2*

Seminarski rad

Klasterovanje skupa podataka Communities and Crime

Student: David Ćuruvija

Broj indeksa: 19/2022

Skup podataka: *Communities and Crime Unnormalized*
Izvor: UCI Machine Learning Repository

Beograd, 2026.

Sadržaj

1 Tekst zadatka **3**

2 Opis podataka **3**
2.1 Izvor i kontekst . . . 3
2.2 Format sirovih podataka . . . 3
2.3 Struktura i opis atributa . . . 4
2.3.1 Identifikatori (5 kolona) . . . 4
2.3.2 Demografske karakteristike (12 kolona) . . . 4
2.3.3 Ekonomske karakteristike (15 kolona) . . . 4
2.3.4 Karakteristike siromaštva i obrazovanja (11 kolona) . . . 4
2.3.5 Porodična struktura (13 kolona) . . . 4
2.3.6 Imigracija (11 kolona) . . . 4
2.3.7 Stambena pitanja (19 kolona) . . . 4
2.3.8 Policija i bezbednost (43 kolone) . . . 5
2.3.9 Ciljne promenljive — stope kriminala (18 kolona) . . . 5
2.4 Nedostajuće vrednosti u sirovim podacima . . . 5

3 Preprocesiranje podataka **5**
3.1 Učitavanje podataka i dodela naziva kolona . . . 5
3.2 Analiza nedostajućih vrednosti . . . 5
3.3 Razdvajanje kolona prema ulozi . . . 6
3.4 Uklanjanje kolona s visokim procentom nedostajućih vrednosti . . . 6
3.5 Imputacija preostalih nedostajućih vrednosti . . . 6
3.6 Standardizacija podataka . . . 6
3.7 Detekcija i tretman autlajera . . . 7
3.8 Formiranje redukovanih skupova atributa . . . 8
3.9 Čuvanje obrađenih podataka . . . 8

4 Opis preprocesiranih podataka **8**
4.1 Struktura fajla `data_preprocessed.csv` . . . 8
4.2 Distribucija obeležja . . . 9
4.3 Korelacijska analiza . . . 9
4.4 Vizuelizacija u 2D i 3D prostoru . . . 9

5 Klasterovanje **10**
5.1 Ulazni skupovi podataka . . . 10
5.2 Metrike evaluacije . . . 10
5.3 Algoritam 1 — K-Means . . . 10
5.4 Algoritam 2 — Aglomerativno hijerarhijsko klasterovanje . . . 11
5.5 Algoritam 3 — DBSCAN . . . 12
5.6 Algoritam 4 — CLARANS . . . 12
5.7 Algoritam 5 — BIRCH . . . 13
5.8 Algoritam 6 — CURE . . . 13
5.9 Pregled i poređenje rezultata svih algoritama . . . 13

6 Evaluacija i interpretacija rezultata **13**
6.1 Poređenje svih konfiguracija . . . 13

6.2 Identifikacija najboljeg modela 14
6.3 Interpretacija klastera 15
6.3.1 Klaster 0 — Ekonomski ugrožene zajednice (49,6%, $n = 1.099$) . 15
6.3.2 Klaster 1 — Zajednice s visokim kriminalom (8,4%, $n = 187$) . . 15
6.3.3 Klaster 2 — Prosperitetne, bezbedne zajednice (41,9%, $n = 929$) 16
6.4 Krajnji zaključci 16

7 Literatura **17**

1. Tekst zadatka

Cilj seminarskog rada jeste primena metoda klasterovanja na skup podataka koji opisuje demografske, ekonomske i kriminološke karakteristike zajednica u Sjedinjenim Američkim Državama. Zadatak obuhvata sledeće korake:

- Obavezno izvršiti preprocesiranje podataka.
- Podatke obraditi traženom metodom koristeći minimum 5 algoritama.
- Izvršiti analizu dobijenih rezultata; uporediti rešenja dobijena za različite algoritme.

Seminarski rad koji se predaje treba da sadrži:

- Tekstualni deo koji sadrži tekst zadatka, opis podataka, opis obrade podataka i opis i tumačenje rezultata. Tekstualni deo se predaje u PDF formatu.
- Podatke (početnu verziju, kao i verziju dobijenu preprocesiranjem).
- Konstruisane modele u odgovarajućem obliku, zavisno od korišćenog alata.
- Materijal koji se šalje mora da sadrži sve što je potrebno za ponavljanje kompletnog postupka u lokalnom okruženju.

Obavezni koraci u istraživanju:

- Vizuelno prikazati podatke u 2D ili 3D prostoru.
- Napraviti modele sa svim atributima i sa različitim redukovanim skupovima atributa i uporediti modele.

2. Opis podataka

2.1. Izvor i kontekst

Skup podataka **Communities and Crime Unnormalized** preuzet je sa UCI Machine Learning repozitorijuma. Ovaj skup podataka kombinuje socioekonomske podatke iz popisa stanovništva SAD iz 1990. godine, podatke o sprovođenju zakona iz LEMAS istraživanja iz 1990. godine i podatke o stopama kriminala iz FBI izveštaja o kriminalu iz 1995. godine. Cilj originalnog istraživanja bio je predviđanje stopa nasilnog kriminala u zajednicama na osnovu demografskih i ekonomskih karakteristika.

Podaci se odnose na **2.215 zajednica** (gradova, okruga i opština) iz različitih saveznih država SAD. Svaki red sadrži sve poznate karakteristike te zajednice iz 1990. ili 1995. godine — demografiju, ekonomiju, stambena pitanja, porodičnu strukturu, imigraciju — i na kraju stope kriminala za tu zajednicu.

2.2. Format sirovih podataka

Sirovi podaci nalaze se u fajlu `CommViolPredUnnormalizedData.txt` (dobijen raspakivanjem preuzetog fajla `communities+and+crime+unnormalized.zip`). Fajl je u *.csv* formatu, bez zaglavlja — prva linija odmah sadrži podatke. Ukupno postoji **147 kolona** (atributa). Nedostajuće vrednosti su označene simbolom `?`.

2.3. Struktura i opis atributa

Svih 147 kolona može se grupisati u nekoliko kategorija:

2.3.1. Identifikatori (5 kolona)

Ove kolone identifikuju svaku zajednicu i ne koriste se u procesu klasterovanja: `communityname` (naziv zajednice), `State` (šifra savezne države), `countyCode` (šifra okruga), `communityCode` (šifra zajednice) i `fold` (indeks koji označava pripadnost instanci određenom podskupu (foldu) za unakrsnu validaciju, definisan u originalnom istraživanju).

2.3.2. Demografske karakteristike (12 kolona)

Opisuju starosnu, rasnu i urbanu strukturu zajednice: ukupna populacija (`pop`), procenat stanovnika različitih rasnih grupacija (`pctBlack`, `pctWhite`, `pctAsian`, `pctHisp`), procenat urbane populacije (`pctUrban`), kao i udeli različitih starosnih grupa (`pct12_21`, `pct12_29`, `pct16_24`, `pct65up`).

2.3.3. Ekonomske karakteristike (15 kolona)

Obuhvataju pokazatelje prihoda: medijana prihoda domaćinstva (`medIncome`), medijana porodičnog prihoda (`medFamIncome`), prihod po glavi stanovnika (`perCapInc`), prihodi po glavi stanovnika po rasnim grupacijama (`whitePerCap`, `blackPerCap`, `hispPerCap` itd.), udeo domaćinstava koja primaju socijalnu pomoć (`pctPubAsst`), penzijska primanja i dr.

2.3.4. Karakteristike siromaštva i obrazovanja (11 kolona)

Podrazumevaju: procenat osoba ispod granice siromaštva (`pctPoverty`, `persPoverty`), procenat nezaposlenih (`pctUnemploy`), procenat bez završene srednje škole (`pctNotHSgrad`), procenat sa visokim obrazovanjem (`pctCollGrad`), zastupljenost zanimanja u prerađivačkoj industriji i menadžmentu.

2.3.5. Porodična struktura (13 kolona)

Ovu kategoriju predstavljaju: udeo razvedenih muškaraca i žena (`pctMaleDivorc`, `pctFemDivorc`), procenat dece koja žive sa oba roditelja (`pct2Par`, `pctKids2Par`, `pctKids4w2Par`), procenat zaposlenih majki, deca rođena van bračne zajednice i dr.

2.3.6. Imigracija (11 kolona)

Kategorija koja obuhvata: broj stranih državljana (`numForeignBorn`), procenat imigranata različitih perioda dolaska (`pctFgnImmig3`, `pctFgnImmig5`, `pctFgnImmig8`, `pctFgnImmig10`), procenat koji govori isključivo engleski (`pctSpeakOnlyEng`) i dr.

2.3.7. Stambena pitanja (19 kolona)

Ova kategorija obuhvata stambena pitanja: broj lica po domaćinstvu, stopa vlasništva nad nekretninama, medijana kirije (`medGrossRent`), procenat stanova praznih duže od 6 meseci (`pctVacant6up`), procenat napuštenih i zazidanih objekata (`pctVacantBoarded`), kvartilni raspon cena nekretnina i kirija i dr.

2.3.8. Policija i bezbednost (43 kolone)

U ovu kategoriju spadaju: broj policajaca, broj policajaca na terenu, broj intervencija, budžet policije, zastupljenost manjina u policijskim snagama, jedinice za nedozvoljene supstance i dr. Ova kategorija ima izrazito visok procenat nedostajućih vrednosti.

2.3.9. Ciljne promenljive — stope kriminala (18 kolona)

Apsolutni broj i stopa (na 100.000 stanovnika) za osam vrsta krivičnih dela: ubistva (`murders`, `murdPerPop`), silovanja (`rapes`, `rapesPerPop`), nasilne pljačke (`robberies`, `robbbPerPop`), napadi (`assaults`, `assaultPerPop`), provale (`burglaries`, `burglPerPop`), krađe (`larcenies`, `larcPerPop`), krađe automobila (`autoTheft`, `autoTheftPerPop`), podmetanja požara (`arsons`, `arsonsPerPop`), ukupna stopa nasilnog kriminala (`violentPerPop`) i nenasilnog kriminala (`nonViolPerPop`).

2.4. Nedostajuće vrednosti u sirovim podacima

Od ukupno 147 kolona, **41 kolona** sadrži nedostajuće vrednosti. Najizraženiji problem je u grupi policijskih atributa — 22 kolone koje se tiču podataka o policiji imaju tačno **1.872 nedostajuće vrednosti**, što odgovara **84,51%** svih redova. Ovaj izrazito visok procenat posledica je metodologije LEMAS ankete — mnoge zajednice nisu učestvovale u istraživanju ili nisu prijavile tražene podatke.

3. Preprocesiranje podataka

Preprocesiranje je sprovedeno u Jupyter svesci `01_preprocessing_eda.ipynb`, korišćenjem Python biblioteka `pandas`, `numpy`, `scikit-learn` i `matplotlib`. U nastavku su opisani svi koraci.

3.1. Učitavanje podataka i dodela naziva kolona

Budući da sirovi fajl ne sadrži zaglavlje, nazivi kolona dodeljeni su ručno, prema zvaničnoj dokumentaciji sa UCI repozitorijuma. Svi specijalni karakteri (crtice) u nazivima kolona zamenjeni su donjim crticama radi kompatibilnosti sa bibliotekom `pandas`. Vrednosti `?` koje označavaju nedostajuće podatke automatski su prepoznate i tretirane kao `NaN` (vrednosti koje nedostaju) prilikom učitavanja.

Nakon učitavanja, potvrđeno je da skup podataka sadrži **2.215 redova i 147 kolona**.

3.2. Analiza nedostajućih vrednosti

Sprovedena je detaljna analiza broja i procenta nedostajućih vrednosti po svakoj koloni. Vizuelizacijom je utvrđeno da postoje dve grupe kolona s nedostajućim vrednostima:

- Kolone s relativno malim brojem nedostajućih vrednosti (ispod 5%), koje se mogu imputovati.
- Kolone podataka o policiji s 84,51% nedostajućih vrednosti, koje nije moguće pouzdano imputovati.

3.3. Razdvajanje kolona prema ulozi

Pre filtriranja, kolone su podeljene u tri logičke grupe:

- **Identifikatori (5 kolona):** Metapodaci koji identifikuju zajednicu; isključeni su iz klasterovanja jer nemaju analitičku vrednost. [1]
- **Prediktivne karakteristike (124 kolone):** Atributi koji opisuju demografske, ekonomske, stambene i socijalne prilike; koriste se kao ulaz za algoritme klasterovanja. [2]
- **Ciljne promenljive (18 kolona):** Stope kriminala; isključene su iz ulaza za klasterovanje kako bi rezultat klasterovanja bio reprezentativan, ali se koriste naknadno za interpretaciju dobijenih klastera.

3.4. Uklanjanje kolona s visokim procentom nedostajućih vrednosti

Primenjen je prag od **40%** — sve kolone u kojima više od 40% vrednosti nedostaje uklonjene su iz skupa prediktivnih karakteristika. Ovaj prag je izabran jer imputacija više od 40% vrednosti unosi previše šuma i može ozbiljno narušiti strukturu podataka.

Uklonjeno je **22 kolone**, i to sve iz grupe podataka o policiji (84,51% nedostajućih vrednosti): `numPolice`, `policePerPop`, `policeField`, `policeFieldPerPop`, `policeCalls`, `policCallPerPop`, `policCallPerOffic`, `racialMatch`, `pctPolicWhite`, `pctPolicBlack`, `pctPolicHisp`, `pctPolicAsian`, `pctPolicMinority`, `policePerPop2`, `officDrugUnits`, `numDiffDrugsSeiz`, `policAveOT`, `policOperBudget`, `gangUnit`, `policCarsAvail`, `pctPolicPatrol`, `policBudgetPerPop`.

Nakon filtriranja, ostale su **102 prediktivne kolone**.

3.5. Imputacija preostalih nedostajućih vrednosti

Nakon uklanjanja kolona sa visokim procentom nedostajućih vrednosti, u skupu podataka ostala je **jedna nedostajuća vrednost** u preostale 102 kolone. Za imputaciju je korišćena **medijana** (strategija `median`) iz klase `SimpleImputer` biblioteke `scikit-learn`. Medijana je izabrana umesto srednje vrednosti jer je robusna na autlajere, koji su prisutni u ovom skupu podataka.

Nakon imputacije, potvrđeno je da **ne postoji nijedna nedostajuća vrednost** u skupu podataka.

3.6. Standardizacija podataka

Primenom `StandardScaler`-a izvršena je **standardizacija** sve 102 kolone. Ovim postupkom svaka kolona transformisana je tako da ima srednju vrednost **0** i standardnu devijaciju **1**. Standardizacija je neophodna jer algoritmi klasterovanja koji koriste euklidsko rastojanje (K-Means, DBSCAN i dr.) daju pristrasne rezultate kada su atributi na različitim skalama — na primer, ukupna populacija zajednice (`pop`) kreće se u stotinama hiljada, dok procenat nezaposlenih (`pctUnemploy`) ima vrednosti između 0 i 100.

[1] Prema dokumentaciji sa UCI Machine Learning repozitorijuma, ova grupa obuhvata 4 kolone, budući da kolona `fold` nije uključena među identifikatore.

[2] Prema dokumentaciji sa UCI Machine Learning repozitorijuma, ova grupa obuhvata 125 kolona, budući da je kolona `fold` uključena među prediktivne karakteristike.

Nakon standardizacije, verifikovano je da je srednja vrednost po svim kolonama bliska **0,0000**, a standardna devijacija bliska **1,0002**, čime je potvrđena ispravnost transformacije.

3.7. Detekcija i tretman autlajera

Autlajeri su detektovani na tri načina:

Z-skor metod. Vrednosti čiji z-skor (broj standardnih devijacija od srednje vrednosti) prelazi 3 tretiraju se kao autlajeri. Utvrđeno je da **98 od 102 kolone** sadrže autlajere, sa ukupno **2.869 autlajera** u celom skupu. Kolone sa najvećim brojem autlajera su kolone vezane za rasnu strukturu i imigraciju — npr. `pctHisp` (67 autlajera), `pctSpeakOnlyEng` (62), `pctNotSpeakEng` (60), `pctBlack` (57).

Logičke granice. Provereno je da li sve procentualne kolone imaju vrednosti u opsegu [0, 100]. Nisu pronađene **nijedne** logički neispravne vrednosti.

Vizuelna inspekcija — kućice. Prikazane su kućice (eng. *box plots*) za 8 ključnih socioekonomskih atributa: `medIncome`, `pctPoverty`, `pctUnemploy`, `pctNotHSgrad`, `pctCollGrad`, `pct2Par`, `popDensity` i `pctBlack`. Analiza kućica dala je sledeće zaključke:

- `medIncome` — Većina zajednica ima prihod između 25.000$ i 45.000$. Postoje brojni autlajeri naviše (bogati gradovi i predgrađa), dok nema autlajera naniže.
- `pctPoverty` — Medijana je oko 10–12%. Distribucija je desno asimetrična — većina zajednica ima relativno nisku stopu siromaštva, ali postoje zajednice sa izrazito visokim stopama (autlajeri do oko 50–60%).
- `pctUnemploy` — Slična situacija kao kod siromaštva. Medijana je oko 5–6%, sa autlajerima koji idu do oko 30%. Većina zajednica ima nisku nezaposlenost.
- `pctNotHSgrad` — Medijana je oko 20–25%. Širok interkvartilni raspon ukazuje na veliku varijabilnost između zajednica. Autlajeri sežu do oko 70%, što znači da postoje zajednice u kojima skoro 70% odraslih nije završilo srednju školu.
- `pctCollGrad` — Medijana je oko 15–20%, sa autlajerima naviše do oko 80% — uglavnom univerzitetski gradovi.
- `pct2Par` — Najuži raspon od svih 8 atributa, medijana oko 65–70%. Relativno malo autlajera, što znači da je porodična struktura konzistentnija između zajednica u odnosu na ostale atribute.
- `popDensity` — Izrazito asimetrična raspodela. Kućica je stisnuta pri dnu (blizu 0), a autlajeri sežu do oko 40.000 ljudi po kvadratnom kilometru — to su veliki metropolitanski gradovi.
- `pctBlack` — Medijana je veoma niska (ispod 10%), kućica je uska, ali postoji veliki broj autlajera naviše do 100%. To odražava rasnu segregaciju u SAD — većina zajednica ima mali procenat crnog stanovništva, dok neke imaju gotovo 100%.

Odluka o tretmanu autlajera. Autlajeri su **zadržani** i nisu uklonjeni. Razlog je to što oni odražavaju stvarne zajednice — npr. metropolitanski gradovi sa izrazito

velikom populacijom ili visokim procentom određenih etničkih grupacija. Uklanjanje ovakvih zajednica iz analize narušilo bi strukturalnu raznovrsnost skupa podataka i vodilo bi gubitku korisnih informacija. Štaviše, standardizacijom su ekstremne apsolutne vrednosti relativizovane u odnosu na distribuciju ostatka podataka.

3.8. Formiranje redukovanih skupova atributa

Pored standardizovanog skupa od 102 atributa, formirana su dodatna tri redukovana skupa koji omogućavaju poređenje algoritama klasterovanja pri različitim konfiguracijama ulaznih podataka.

PCA redukcija na 70% objašnjene varijanse. Primenom analize glavnih komponenti (PCA) utvrđeno je da je potrebno **7 komponenti** da bi se objasnilo 70% ukupne varijanse u podacima. Ovaj skup sačuvan je kao `data_pca_70.csv`.

PCA redukcija na 80% objašnjene varijanse. Za 80% objašnjene varijanse potrebno je **12 komponenti**. Ovaj skup sačuvan je kao `data_pca_80.csv`. Kriva kumulativne objašnjene varijanse u zavisnosti od broja komponenti vizuelizovana je i sačuvana.

Ekonomski podskup (selekcija na osnovu domenskog znanja). Na osnovu kriminološke literature i poznatih korelacija između socioekonomskih faktora i kriminala, ručno je odabrano **20 ekonomski relevantnih atributa**: `medIncome`, `pctPoverty`, `pctUnemploy`, `pctNotHSgrad`, `pctCollGrad`, `pct2Par`, `perCapInc`, `pctBlack`, `pctWhite`, `pctHisp`, `medFamIncome`, `pctPubAsst`, `pctWsocsec`, `pctRetire`, `pctMaleDivorc`, `pctFemDivorc`, `pctKids2Par`, `pop`, `popDensity`, `pctUrban`. Ovaj podskup sačuvan je kao `data_economic.csv` i omogućava interpretabilno klasterovanje zasnovano na razumljivim ekonomskim dimenzijama, za razliku od PCA komponenti koje nemaju direktnu semantičku interpretaciju.

3.9. Čuvanje obrađenih podataka

Tokom preprocesiranja sačuvano je šest izlaznih fajlova, prikazanih u tabeli 1.

Tabela 1: Izlazni fajlovi generisani tokom preprocesiranja

Fajl	**Sadržaj**	**Dimenzije**
`data_preprocessed.csv`	102 standardizovane karakteristike	2215×102
`data_pca_70.csv`	7 PCA komponenti (70% varijanse)	2215×7
`data_pca_80.csv`	12 PCA komponenti (80% varijanse)	2215×12
`data_economic.csv`	20 ekonomskih atributa (skalirani)	2215×20
`data_targets.csv`	18 ciljnih promenljivih (kriminal)	2215×18
`data_imputed.csv`	Imputovani neskalirani atributi	2215×102

4. Opis preprocesiranih podataka

4.1. Struktura fajla `data_preprocessed.csv`

Fajl `data_preprocessed.csv` predstavlja glavni ulazni skup podataka za algoritme klasterovanja. Sadrži **2.215 redova** (po jedan za svaku zajednicu) i **102 kolone** (prediktivne karakteristike). Za razliku od sirovih podataka, ovaj fajl poseduje zaglavlje sa nazivima kolona.

Sve vrednosti su standardizovane: pozitivne vrednosti označavaju da je data zajednica iznad proseka za tu karakteristiku, a negativne da je ispod proseka. Vrednost 0 odgovara proseku. Na primer, zajednica sa vrednošću +2,5 za atribut `pctPoverty` ima stopu siromaštva koja je za 2,5 standardnih devijacija viša od proseka svih 2.215 zajednica.

4.2. Distribucija obeležja

Eksploratorna analiza podataka (EDA) otkrila je sledeće karakteristike distribucija:

Socioekonomska obeležja. Distribucije ključnih socioekonomskih atributa pokazuju različite oblike. Medijana prihoda (`medIncome`) ima blago desno asimetričnu distribuciju. Stopa siromaštva (`pctPoverty`) i nezaposlenosti (`pctUnemploy`) takođe pokazuju desnu asimetriju, što ukazuje da je većina zajednica sa relativno niskim stopama navedenih karakteristika, ali postoji manji broj zajednica sa izrazito visokim stopama istih. Procenat dece sa oba roditelja (`pct2Par`) ima distribuciju nalik normalnoj, sa centralnom tendencijom oko 70%.

Stope kriminala (ciljne promenljive). Sve stope kriminala pokazuju izrazitu pozitivnu asimetriju — dominantan broj zajednica ima niske stope kriminala, dok mali broj zajednica ima ekstremno visoke stope. Ovo je karakteristično za kriminološke podatke i direktno utiče na strukturu klastera.

4.3. Korelacijska analiza

Analiza korelacije između ključnih ekonomskih atributa i stopa kriminala otkrila je očekivane i statistički značajne veze:

- **Siromaštvo i kriminal:** `pctPoverty` ima visoku pozitivnu korelaciju sa nasilnim kriminalom (`violentPerPop`), ubistvima (`murdPerPop`) i pljačkom (`robbbPerPop`).
- **Obrazovanje i kriminal:** `pctNotHSgrad` (procenat bez završene srednje škole) pozitivno korelira sa kriminalom, dok `pctCollGrad` (procenat sa visokim obrazovanjem) negativno korelira sa kriminalom.
- **Porodična struktura:** `pct2Par` (procenat dece sa oba roditelja) ima izrazitu negativnu korelaciju sa nasilnim kriminalom — zajednice sa višim procentom potpunih porodica imaju niže stope kriminala.
- **Rasna struktura:** `pctBlack` pokazuje pozitivnu korelaciju sa kriminalom, ali ova korelacija je posredovana socioekonomskim faktorima (siromaštvo, stambena segregacija) koji su posledica sistemske nejednakosti.

4.4. Vizuelizacija u 2D i 3D prostoru

Radi vizuelnog pregleda strukture podataka, primenjena je PCA u dve i tri dimenzije.

2D PCA vizuelizacija. Prve dve glavne komponente objašnjavaju **39,97%** ukupne varijanse. Zajednice su obojene prema kvartilima stope nasilnog kriminala (četiri kategorije: niska, srednje-niska, srednje-visoka, visoka). Vizuelizacija ukazuje na delimičnu separabilnost zajednica sa različitim stopama kriminala, što sugeriše da su karakteristike korisne za klasterovanje.

3D PCA vizuelizacija. Prve tri glavne komponente objašnjavaju **48,75%** ukupne varijanse. Trodimenzionalni prikaz pruža bolji uvid u strukturu podataka i potvrđuje tendenciju grupisanja zajednica sličnih socioekonomskih profila.

Relativno nizak procenat objašnjene varijanse (oko 49% za tri komponente) ukazuje na visoku dimenzionalnost podataka i složene međuzavisnosti između atributa, što opravdava korišćenje naprednih algoritama klasterovanja umesto jednostavnih metoda.

5. Klasterovanje

Klasterovanje je sprovedeno u Jupyter svesci `02_clustering.ipynb`. Primenjeno je šest algoritama klasterovanja: *K-Means*, *aglomerativno hijerarhijsko klasterovanje*, *DBSCAN*, *CLARANS*, *BIRCH* i *CURE*. Svaki algoritam je primenjen na više skupova ulaznih podataka radi poređenja performansi.

5.1. Ulazni skupovi podataka

Za klasterovanje su korišćena četiri skupa podataka dobijena u fazi preprocesiranja:

- **Potpuni skup** (`data_preprocessed.csv`) — sve 102 standardizovane karakteristike, oblika 2215×102.
- **PCA-70** (`data_pca_70.csv`) — 7 glavnih komponenti koje objašnjavaju 70% varijanse, oblika 2215×7.
- **PCA-80** (`data_pca_80.csv`) — 12 glavnih komponenti koje objašnjavaju 80% varijanse, oblika 2215×12.
- **Ekonomski podskup** (`data_economic.csv`) — 20 ručno odabranih socioekonomskih karakteristika, oblika 2215×20.

Radi vizuelizacije klastera, svi skupovi su projektovani na 2D prostor primenom PCA sa dve komponente.

5.2. Metrike evaluacije

Za evaluaciju kvaliteta klastera korišćene su tri standardne metrike:

- **Silueta koeficijent** (eng. *Silhouette Score*) — meri koliko je svaka tačka slična sopstvenom klasteru u poređenju sa najbližim susednim klasterom. Vrednosti su u opsegu $[-1, 1]$; vrednosti bliže 1 ukazuju na dobro definisane klastere.
- **Davies-Bouldinov indeks** (eng. *Davies-Bouldin Index*) — meri prosečnu sličnost svakog klastera sa njemu najsličnijim klasterom. Niže vrednosti su bolje.
- **Calinski-Harabaszov indeks** (eng. *Calinski-Harabasz Index*) — odnos između međuklasterske i unutarklasterske raspršenosti. Više vrednosti su bolje.

5.3. Algoritam 1 — K-Means

K-Means je iterativni algoritam koji deli podatke u k klastera tako što minimizuje sumu kvadrata rastojanja tačaka od centroida njihovog klastera. Pre primene algoritma, određen je optimalan broj klastera k.

Izbor optimalnog k. Primenjena su dva kriterijuma: *metoda lakta* (eng. *elbow method*) koja prati promenu inercije (ukupne sume kvadrata rastojanja) u zavisnosti od k i silueta koeficijent. Testirane su vrednosti $k \in \{2, 3, \ldots, 10\}$ na potpunom skupu. Rezultati su pokazali da $k = 3$ daje najviši silueta koeficijent od **0,1777**, te je $k = 3$ odabrano kao optimalno.

Primena. Algoritam je zatim primenjen sa $k = 3$ na sva četiri skupa podataka. Rezultati su prikazani u tabeli 2.

Tabela 2: Rezultati K-Means klasterovanja ($k = 3$)

Skup podataka	**Silueta**	**Davies-Bouldin**	**Calinski-Harabasz**
Potpuni (102 kar.)	0,1777	1,7846	370,6
PCA-70 (7 komp.)	0,2686	1,3279	606,3
PCA-80 (12 komp.)	0,2277	1,5045	502,4
Ekonomski (20 kar.)	0,2065	1,6030	720,4

Najbolji rezultat postiže se na PCA-70 skupu (silueta koeficijent 0,2686), dok potpuni skup daje najlošije rezultate. Ovo sugeriše da redukcija dimenzionalnosti poboljšava kvalitet klastera kod K-Means algoritma.

5.4. Algoritam 2 — Aglomerativno hijerarhijsko klasterovanje

Aglomerativno hijerarhijsko klasterovanje gradi hijerarhiju klastera odozdo naviše: svaka tačka počinje kao zaseban klaster, a zatim se najsličniji klasteri spajaju sve dok se ne dostigne željeni broj klastera. Način merenja sličnosti između klastera određuje metoda vezivanja (eng. *linkage*).

Dendrogram. Radi vizuelnog uvida u hijerarhijsku strukturu podataka, konstruisan je dendrogram primenom Ward metode vezivanja na prvih 500 instanci PCA-70 skupa. Dendrogram prikazuje na kom nivou sličnosti se klasteri spajaju i pomaže u proceni prirodnog broja klastera.

Metode vezivanja. Algoritam je testiran sa tri metode:

- **Ward** — bira par klastera čijim potencijalnim spajanjem dolazi do najmanjeg povećanja kvadratne greške.
- **Complete** (potpuna veza) — rastojanje između klastera definiše kao maksimalno rastojanje između bilo koja dva člana.
- **Average** (grupno-prosečna veza) — rastojanje između klastera definiše kao prosek svih međusobnih rastojanja članova.

Algoritam je primenjen sa $k = 3$ na sva četiri skupa podataka za svaku metodu. Zanimljivo je da metode *complete* i *average* postižu izrazito visoke silueta koeficijente (do **0,7693** na PCA-70), dok Ward metoda daje znatno niže vrednosti (do 0,2325). Ovakva razlika ukazuje da *complete* i *average* metode formiraju kompaktnije i bolje razdvojene klastere na ovom skupu podataka, ali je važno napomenuti da ove metode mogu biti osetljivije na autlajere. Rezultati Ward metode su konzistentni sa K-Means i ostalim algoritmima.

5.5. Algoritam 3 — DBSCAN

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) je algoritam klasterovanja zasnovan na gustini. Za razliku od K-Means i hijerarhijskog klasterovanja, DBSCAN ne zahteva unapred definisan broj klastera — klastere pronalazi kao oblasti visoke gustine tačaka u prostoru obeležja.

Dva ključna parametra ovog algoritma su:

- ε (`eps`) — poluprečnik okoline oko svake tačke.
- `min_samples` — minimalni broj tačaka u ε-okolini da bi tačka bila smatrana jezgrom klastera.

Izbor parametara. Za određivanje optimalnog ε korišćen je *k-distance graf*: za svaku tačku izračunato je rastojanje do petog najbližeg suseda (`k=5`), a vrednosti su sortirane i vizuelizovane. Lakat na grafu ukazuje na odgovarajuću vrednost ε. Testirano je više kombinacija parametara na PCA-70 skupu. Optimalna konfiguracija određena je kao $\varepsilon = 4{,}0$ i `min_samples` $= 5$, koja daje 3 klastera, 95 šumnih tačaka i silueta koeficijent od **0,5612**.

Primena. Algoritam sa optimalnim parametrima primenjen je na tri skupa podataka. Rezultati su prikazani u tabeli 3.

Tabela 3: Rezultati DBSCAN klasterovanja ($\varepsilon = 4{,}0$, `min_samples`=5)

Skup podataka	**Br. klastera**	**Šum**	**Silueta**
PCA-70	3	95	0,5612
PCA-80	7	315	0,0393
Ekonomski	1	13	—

DBSCAN postiže odličan rezultat na PCA-70 skupu, ali je veoma osetljiv na izbor parametara i dimenzionalnost ulaznih podataka — na PCA-80 skupu pronalazi 7 klastera sa velikim brojem šumnih tačaka, a na ekonomskom skupu svrstava gotovo sve tačke u jedan klaster.

5.6. Algoritam 4 — CLARANS

CLARANS (*Clustering Large Applications based on RANdomized Search*) je algoritam zasnovan na k-medoida pristupu. Za razliku od K-Means koji koristi centroide (srednje vrednosti klastera), CLARANS koristi medoide — stvarne tačke iz skupa podataka koje su reprezentativne za klaster. Pretraga optimalnih medoida vrši se nasumičnim pretraživanjem prostora rešenja.

Ključni parametri algoritma su `numlocal` (broj pokušaja pronalaženja lokalnog optimuma) i `maxneighbor` (maksimalni broj suseda koji se razmatraju po iteraciji).

S obzirom na kvadratnu vremensku složenost algoritma $O(n^2)$, klasterovanje je izvršeno na nasumičnom uzorku od **300 instanci** (umesto svih 2.215). Korišćeni parametri su $k = 3$, `numlocal` $= 2$ i `maxneighbor` $= 5$. Algoritam je primenjen na PCA-70, PCA-80 i ekonomski skup. Silueta koeficijenti kreću se u opsegu 0,185–0,2275, što je uporedivo sa algoritmima K-Means i BIRCH.

5.7. Algoritam 5 — BIRCH

BIRCH (*Balanced Iterative Reducing and Clustering using Hierarchies*) je algoritam koji najpre komprimuje podatke u kompaktnu strukturu stabla (CF-stablo, *Clustering Feature tree*), a zatim primenjuje K-Means na listovima tog stabla. Ova arhitektura čini BIRCH posebno pogodnim za velike skupove podataka jer ne mora sve instance držati u memoriji istovremeno.

Ključni parametar je `threshold` (prag) koji kontroliše maksimalni prečnik potprostora koji jedan čvor CF-stabla može da pokrije. Korišćen je `threshold` = 0,5 i $k = 3$ na sva četiri skupa podataka. Rezultati su slični K-Means algoritmu, s tim što PCA-70 ponovo daje najbolje rezultate (silueta koeficijent = 0,2429).

5.8. Algoritam 6 — CURE

CURE (*Clustering Using REpresentatives*) je hijerarhijski algoritam koji svaki klaster predstavlja sa više reprezentativnih tačaka (umesto jednog centroida), koje su zatim "skupljene" prema centru klastera za zadati faktor kompresije. Ovaj pristup čini CURE robusnim na klastere nepravilnih oblika, kao i na autlajere.

Korišćeni parametri: $k = 3$, broj reprezentativnih tačaka po klasteru = 5, faktor kompresije = 0,5. Algoritam je primenjen na PCA-70, PCA-80 i ekonomski skup. Na PCA-80 skupu, silueta koeficijent dostiže vrednost **0,7504**, a na ekonomskom skupu **0,6796**.

5.9. Pregled i poređenje rezultata svih algoritama

Na osnovu rezultata mogu se izvući sledeći zaključci:

- **Aglomerativno hijerarhijsko klasterovanje i CURE** dominiraju po silueta koeficijentu na svim skupovima podataka na kojima su primenjeni, postižući vrednosti znatno iznad ostalih algoritama.
- **DBSCAN** na PCA-70 skupu postiže solidan rezultat (0,5612) i jedini je algoritam koji automatski određuje broj klastera.
- **PCA-redukovani skupovi** konzistentno daju bolje rezultate od potpunog skupa sa 102 karakteristike, što potvrđuje da redukcija dimenzionalnosti smanjuje šum i poboljšava separabilnost klastera.
- **Potpuni skup** sa 102 karakteristike daje najlošije rezultate kod svih algoritama, što je posledica prokletstva dimenzionalnosti (eng. *curse of dimensionality*).

6. Evaluacija i interpretacija rezultata

Evaluacija je sprovedena u Jupyter svesci `03_evaluation.ipynb`. Obuhvata poređenje svih 21 konfiguracija (6 algoritama × do 4 skupa podataka) po svim trima metrikama, identifikaciju najboljeg modela, vizuelno poređenje i interpretaciju klastera.

6.1. Poređenje svih konfiguracija

Tabela 4 prikazuje sve konfiguracije sortirane opadajuće po silueta koeficijentu.

Tabela 4: Sve konfiguracije sortirane po silueta koeficijentu

Algoritam	**Skup**	**Silueta ↑**	**Davies-Bouldin ↓**	**Calinski-H. ↑**
Aglomerativno (Average)	PCA-70	0,7693	0,2680	106,1
Aglomerativno (Complete)	PCA-70	0,7693	0,2680	106,1
Aglomerativno (Average)	PCA-80	0,7504	0,2869	93,0
CURE	PCA-80	0,7504	0,2869	93,0
Aglomerativno (Complete)	PCA-80	0,7504	0,2869	93,0
Aglomerativno (Complete)	Full	0,7278	0,3817	75,1
Aglomerativno (Average)	Economic	0,6796	0,3130	47,9
CURE	Economic	0,6796	0,3130	47,9
CURE	PCA-70	0,6561	0,4540	110,1
Aglomerativno (Average)	Full	0,6112	0,5541	78,2
DBSCAN	PCA-70	0,5612	0,6230	62,3
Aglomerativno (Complete)	Economic	0,4685	0,6183	86,9
K-Means	PCA-70	0,2686	1,3279	606,3
BIRCH	PCA-70	0,2429	1,4122	540,3
Aglomerativno (Ward)	PCA-70	0,2325	1,4068	504,6
K-Means	PCA-80	0,2277	1,5045	502,4
CLARANS	PCA-70	0,2273	1,6038	321,5
Aglomerativno (Ward)	Economic	0,2118	1,6467	608,0
K-Means	Economic	0,2065	1,6030	720,4
CLARANS	Economic	0,1988	1,6531	573,4

Grafičkim prikazom metrika (trakasti dijagrami po algoritmu i skupu podataka, kao i toplotna mapa silueta koeficijenata u obliku matrice algoritam × skup podataka) potvrđeni su sledeći obrasci:

- **Aglomerativno hijerarhijsko klasterovanje** dominira po silueta koeficijentu i Davies-Bouldinovom indeksu na svim skupovima na kojima je testirano (potpuna i grupno-prosečna veza).
- **Calinski-Harabaszov indeks** daje drugačiji redosled — prednjače K-Means i aglomerativno hijerarhijsko klasterovanje (Ward-ov metod) na ekonomskom skupu (vrednosti 720,4 i 608,0), dok aglomerativno hijerarhijsko klasterovanje korišćenjem potpune veze i grupno-prosečne veze beleži umerene vrednosti, što ukazuje na to da se formiraju visoko separabilni klasteri koji nisu nužno kompaktni u smislu unutarklasterske raspršenosti.
- **Potpuni skup** (102 karakteristike) konzistentno daje najlošije rezultate kod svih algoritama, što potvrđuje efekat prokletstva dimenzionalnosti.
- **DBSCAN** je izrazito osetljiv na izbor skupa podataka — odlično radi na PCA-70, a na ekonomskom skupu svrstava gotovo sve zajednice u jedan klaster.

6.2. Identifikacija najboljeg modela

Na osnovu silueta koeficijenta i Davies-Bouldinovog indeksa, **aglomerativno hijerarhijsko klasterovanje korišćenjem grupno-prosečne veze primenjeno na PCA-70 skupu** identifikovano je kao najbolja konfiguracija:

- Silueta koeficijent: **0,7693**

- Davies-Bouldinov indeks: **0,2680**
- Broj klastera: **3**

Ovo predstavlja poboljšanje silueta koeficijenta za faktor **4,2**× u poređenju sa polaznom konfiguracijom K-Means na potpunom skupu (0,1777). Vizuelnim poređenjem u 2D PCA prostoru jasno se vidi da ovaj algoritam formira kompaktne i dobro razdvojene grupacije tačaka, dok K-Means/Potpuni skup pokazuje izraženo preklapanje klastera.

6.3. Interpretacija klastera

Za interpretaciju klastera korišćen je K-Means model primenjen na potpunom skupu (sve 102 karakteristike), iako nije postigao najviše metričke vrednosti. Razlog za ovaj izbor je dvostruk: svaka zajednica je dodeljena tačno jednom klasteru (bez šumnih tačaka kao kod DBSCAN), a korišćenje svih 102 socioekonomskih promenljivih daje potpuniji profil svakog klastera.

Medijane socioekonomskih indikatora i stopa kriminala po klasterima prikazane su u tabeli 5.

Tabela 5: Profili klastera — medijane ključnih indikatora

Indikator	**Klaster 0**	**Klaster 1**	**Klaster 2**
Broj zajednica	1.099 (49,6%)	187 (8,4%)	929 (41,9%)
medIncome ($)	24.509	29.206	43.309
pctPoverty (%)	15,30	16,82	3,98
pctUnemploy (%)	6,77	8,52	3,96
pctCollGrad (%)	15,86	14,06	28,42
pct2Par (%)	69,00	70,65	83,18
violentPerPop	549,22	950,51	190,84
murdPerPop	5,24	10,61	0,00
burglPerPop	1.093,04	1.391,24	548,10

Na osnovu ovih profila, klasterima su dodeljeni opisni nazivi:

6.3.1. Klaster 0 — Ekonomski ugrožene zajednice (49,6%, $n = 1.099$)

Ovaj klaster obuhvata skoro polovinu svih zajednica i karakteriše ga najniži medijanski prihod (24.509$), visoka stopa siromaštva (15,3%) i nisko obrazovanje (15,86% sa visokom školom). Stope nasilnog kriminala su umerene (549 na 100.000 stanovnika), ali stopa provala je visoka (1.093). Dominantan problem ovih zajednica su krivična dela imovinskog tipa.

6.3.2. Klaster 1 — Zajednice s visokim kriminalom (8,4%, $n = 187$)

Najmanji klaster, ali najproblematičniji. Beleži **najviše stope svih oblika kriminala**: za nasilni kriminal 950,51, za ubistva 10,61 i za provale 1.391,24 na 100.000 stanovnika. Socioekonomski profil: visoka nezaposlenost (8,52%), visoko siromaštvo (16,82%) i najniže obrazovanje (14,06%). Ove zajednice predstavljaju žarišta kriminala sa izrazito nepovoljnim socioekonomskim uslovima.

6.3.3. Klaster 2 — Prosperitetne, bezbedne zajednice (41,9%, $n = 929$)

Zajednice s **najnižim stopama kriminala**: nasilni kriminal svega 190,84, medijana ubistava 0, a provale 548,10. Karakteriše ih najviši prihod (43.309$), najniži procenat siromaštva (3,98%), najniži procenat nezaposlenosti (3,96%), najviši procenat obrazovanja (28,42% sa visokim obrazovanjem) i najjača porodična struktura (83,18% dece živi sa oba roditelja). Ovo su prosperitetne, obrazovane zajednice sa stabilnim porodičnim okruženjem.

6.4. Krajnji zaključci

Istraživanje je pokazalo da se 2.215 američkih zajednica prirodno grupiše u tri karakteristična tipa koji se jasno razlikuju po socioekonomskim prilikama i stopama kriminala. Potvrđena je snažna veza između siromaštva, nezaposlenosti, niskog obrazovanja i visokog kriminala, kao i između ekonomskog prosperiteta, obrazovanja, porodične stabilnosti i niske stope kriminala.

Od šest testiranih algoritama, **aglomerativno hijerarhijsko klasterovanje korišćenjem grupno-prosečne veze** postiže najbolje rezultate po silueta koeficijentu i Davies-Bouldinovom indeksu, posebno u kombinaciji sa PCA-redukovanjem na 70% varijanse. **Redukcija dimenzionalnosti** putem PCA dosledno poboljšava rezultate svih algoritama u poređenju sa potpunim skupom od 102 karakteristike, što potvrđuje korisnost ove tehnike u pripremi podataka za klasterovanje.

7. Literatura

1. UCI Machine Learning Repository: *Communities and Crime Unnormalized* — obrađivani i analizirani skup podataka.
   https://archive.ics.uci.edu/dataset/211/communities+and+crime+unnormalized
2. Maljković Ružičić, M.: *Priprema podataka* — slajdovi sa predavanja, Istraživanje podataka 2, Matematički fakultet, Univerzitet u Beogradu.
   https://www.istrazivanjepodataka.matf.bg.ac.rs/ip2/ip2.materijali/ip.priprema.podataka.html
3. Maljković Ružičić, M.: *Klasterovanje* — slajdovi sa predavanja, Istraživanje podataka 2, Matematički fakultet, Univerzitet u Beogradu.
   https://www.istrazivanjepodataka.matf.bg.ac.rs/ip2/ip2.materijali/ip2.klasterovanje.html
4. Mitić, N.: *Priprema podataka* — slajdovi sa predavanja, Istraživanje podataka 1, Matematički fakultet, Univerzitet u Beogradu.
   https://poincare.matf.bg.ac.rs/~nenad/ip1/3.Priprema_podataka.pdf
5. Mitić, N.: *Vizuelizacija* — slajdovi sa predavanja, Istraživanje podataka 1, Matematički fakultet, Univerzitet u Beogradu.
   https://poincare.matf.bg.ac.rs/~nenad/ip1/4.Vizuelizacija.pdf
6. Mitić, N.: *Uvod u klaster analizu* — slajdovi sa predavanja, Istraživanje podataka 1, Matematički fakultet, Univerzitet u Beogradu.
   https://poincare.matf.bg.ac.rs/~nenad/ip1/13.uvod_u_klaster_analizu.pdf
7. Mitić, N.: *Algoritmi klasterovanja* — slajdovi sa predavanja, Istraživanje podataka 1, Matematički fakultet, Univerzitet u Beogradu.
   https://poincare.matf.bg.ac.rs/~nenad/ip1/14.algoritmi_klasterovanja.pdf
8. Mitić, N.: *Otkrivanje anomalija* — slajdovi sa predavanja, Istraživanje podataka 1, Matematički fakultet, Univerzitet u Beogradu.
   https://poincare.matf.bg.ac.rs/~nenad/ip1/15.otkrivanje_anomalija.pdf
9. Tan, P., Steinbach, M., Karpatne, A., Kumar, V.: *Introduction to Data Mining*, 2nd edition, Pearson Education, 2019.
10. Kapunac, S., Erić, M.: Kodovi sa vežbi, Istraživanje podataka 1, Matematički fakultet, Univerzitet u Beogradu, 2022/2023.
    https://github.com/MATF-istrazivanje-podataka-1/materijali_2022-2023